

Сравнительное исследование методов машинного обучения, глубокого обучения и фундаментальных моделей для краткосрочного прогнозирования электрической нагрузки

Автор Один
Аффилиация Один
Город, Страна
email1@example.com

Автор Два
Аффилиация Два
Город, Страна
email2@example.com

Аннотация—Краткосрочное прогнозирование электрической нагрузки является ключевым компонентом эксплуатации интеллектуальных энергосетей, опережающего планирования и промышленного энергоменеджмента. В работе представлен воспроизводимый бенчмарк, сравнивающий два классических базовых метода (SeasonalNaive и грид-настроенный SARIMA), модель градиентного бустинга (XGBoost), три нейросетевые архитектуры (DLinear, PatchTST, iTransformer) и две фундаментальные модели временных рядов (Chronos-Bolt-Small и TimesFM 2.5). Основная оценка проводится на наборе ECL по агрегированной нагрузке. ETTh1 используется как вторичный промышленный бенчмарк с целевой переменной HUFL; температура масла ОТ целенаправленно не рассматривается как электрическая нагрузка. Эксперименты охватывают горизонты 24, 96 и 168 часов при фиксированном контексте 336 часов. На ECL три лидирующие модели — TimesFM, Chronos-Bolt и XGBoost — отличаются друг от друга в пределах примерно 0.1–0.4% по горизонтам: TimesFM незначительно лучше при $H=24$, XGBoost — при $H=96$ и $H=168$; грид-настроенный SARIMA закрывает большую часть оставшегося разрыва без обучаемых признаков. На ETTh1/HUFL Chronos-Bolt лучшая при $H=24$, DLinear — при $H=96$ и $H=168$. Результаты показывают, что фундаментальные модели конкурентоспособны в zero-shot режиме, но классические и обучаемые на целевом ряду модели остаются сильными при наличии данных и инженерии признаков.

Index Terms—краткосрочное прогнозирование нагрузки, временные ряды, глубокое обучение, фундаментальные модели, SARIMA, XGBoost, интеллектуальная сеть

I. Введение

Краткосрочное прогнозирование нагрузки (STLF) поддерживает диспетчерское планирование, балансировку, тарифно-ориентированное управление, планирование обслуживания и аномально-чувствительный промышленный энергоменеджмент. В современных задачах smart-grid и Industry 4.0 от моделей прогноза требуется не только точность, но и воспроизводимость, вычислительная экономичность и устойчивость к различным режимам эксплуатации.

Методологический ландшафт широк. Классические методы, такие как ARIMA-семейство и сезонные на-

ивные базовые модели, остаются важными референсами; модели машинного обучения вроде градиентного бустинга привлекательны тем, что включают лаговые и календарные признаки при умеренной инженерии; современные модели глубокого обучения и фундаментальные модели обещают более широкую переносимость между доменами временных рядов. Это порождает практический вопрос: когда дорогие архитектуры или zero-shot фундаментальные модели действительно превосходят сильные недорогие базовые методы?

В работе представлено воспроизводимое исполнение бенчмарка на двух открытых наборах данных. Прагматический вклад: (i) сквозной репозиторий с валидацией данных, leakage-aware шкалированием, метриками, измерением времени, фигурами и сборкой статьи; (ii) реальные результаты для SeasonalNaive, грид-настроенного SARIMA, XGBoost, DLinear, PatchTST, iTransformer, Chronos-Bolt-Small и TimesFM 2.5; (iii) тесты Дибольда–Мариано, рассчитанные по поопыткам; (iv) анализ accuracy-latency, отделяющий стоимость развёртывания от чистой точности.

II. Обзор литературы

Классические методы прогнозирования временных рядов, в частности ARIMA-семейство, остаются важными, потому что задают интерпретируемые и недорогие референсы; автоматический выбор порядков по информационным критериям, таким как AICс, делает их применимыми по отдельным рядам [1]. Подходы машинного обучения на основе лагов, календарных переменных и градиентно-бустированных деревьев широко используются в задачах прогнозирования нагрузки благодаря быстрому обучению и устойчивости при инженерии табличных признаков [2]. Модели глубокого обучения, такие как LSTM [3], архитектуры с механизмом внимания [4], Informer [5], DLinear [6], PatchTST [7], iTransformer [8], TimesNet [9], существенно расширили инструментарий долгосрочного прогнозирования.

Фундаментальные модели временных рядов, такие как TimesFM [10] и семейство Chronos [11], мотивируют новую ось оценки: безобучаемое инференс-время против полноценного обучения на целевом наборе. В данной работе используется дистиллированный вариант Chronos-Bolt-Small. Корректное сравнение должно учитывать риск того, что открытые бенчмарки могли быть включены в претренировочные корпуса, поэтому zero-shot результаты на ECL или ETTh1 нельзя интерпретировать как гарантированную обобщающую способность на невиданных данных.

III. Методология

При заданном одномерном контекстном окне $\mathbf{x}_{t-L+1:t}$ задача — предсказать $\hat{\mathbf{y}}_{t+1:t+H}$ для горизонтов $H \in \{24, 96, 168\}$. Эксперименты используют фиксированную длину контекста $L = 336$ часов, что включает суточную и недельную сезонные компоненты и допускает использование лага 168.

Базовая модель SeasonalNaive повторяет последний наблюденный суточный сезонный паттерн. Базовая модель SARIMA использует выбор по AICs на тренировочной выборке из фиксированного грида: пробуются порядки $(p, d, q) \in \{(1, 1, 1), (2, 1, 1), (1, 1, 2), (2, 1, 2)\}$ и сезонные порядки $(P, D, Q)_{24} \in \{(1, 1, 1), (2, 1, 1), (1, 1, 2)\}$, и далее минимально-AICс-фит применяется к каждому тестовому окну через фильтрацию состояния, без перепогонки на каждом окне. XGBoost обучается как прямой многошаговый регрессор на лагах 1, 24, 168, скользящих средних по 24 и 168 часам и циклических календарных признаках. DLinear, PatchTST и iTransformer обучаются через NeuralForecast в той же одноцелевой постановке, с коротким validation-only перебором learning-rate по $\{10^{-3}, 5 \cdot 10^{-4}\}$ и ранним остановом. Обучение и оценка нейросетевых моделей используют rolling-origin cross-validation в NeuralForecast: хотя train, validation и test конкатенируются для построения скользящих окон, каждое окно прогнозируется только по прошлым наблюдениям, поэтому утечки будущей информации в обучение нет. Chronos-Bolt-Small и TimesFM 2.5 оцениваются в zero-shot режиме без обучения на целевом ряду. Все процедуры предобработки для обучаемых моделей подгоняются только на тренировочной части, а метрики считаются после обратного преобразования предсказаний на исходную шкалу. Фундаментальные модели и SARIMA оцениваются непосредственно в исходной шкале.

Рис. 1 обобщает экспериментальный пайплайн.

IV. Постановка эксперимента

Основной набор данных — ECL, обработанный как агрегированная часовая электрическая нагрузка по 321 клиенту. Вторичный набор — ETTh1, целевая переменная HUFL. Переменная OT в ETTh1 — температура



Рис. 1. Экспериментальный пайплайн.




Рис. 2. Пример прогнозов на 168 часов для ECL у репрезентативных моделей.

масла и не рассматривается как электрическая нагрузка. ECL разбивается хронологически 70% train, 10% validation, 20% test. ETTh1 использует стандартное хронологическое разбиение 12 / 4 / 4 месяца.

Точность измеряется метриками MAE, RMSE, sMAPE и wMAPE. Эффективность измеряется временем обучения, single-window inference latency (batch size 1), числом обучаемых параметров и пиковым потреблением GPU-памяти. Обучаемые модели (XGBoost, DLinear, PatchTST, iTransformer) оцениваются по пяти сидам (42–46) и приводятся как среднее $\pm$ СКО; детерминированные модели (SeasonalNaive, SARIMA, Chronos-Bolt, TimesFM) оцениваются однократно и имеют нулевое стандартное отклонение по построению. Тесты Дибольда–Мариано вычисляются по поокно-ошибкам для двух топ-моделей по MAE при сиде 42 для каждой пары (датасет, горизонт). Поскольку усреднение по окнам и плоский поточечный MAE взвешивают ошибки по-разному, ранжирование по статистическим тестам может слегка отличаться от ранжирования таблиц при близких моделях.

V. Результаты

На ECL сильнейшую группу образуют XGBoost и две фундаментальные модели. TimesFM имеет наименьший поточечный MAE при $H=24$, но разрыв до XGBoost и Chronos-Bolt — менее 0.1%, поэтому практическое ранжирование среди этих трёх по сути плоское на коротком горизонте. На $H=96$ и $H=168$ незначительно лучше XGBoost, при этом Chronos-Bolt находится в пределах примерно 0.3% от лучшего на всех трёх горизонтах. Грид-настроенный SARIMA отстаёт от верхней группы примерно на 1.6–2.7%, опережая

Таблица I
Accuracy on ECL test split.

Model	H	MAE	RMSE	sMAPE (%)	wMAPE (%)
timesfm	24	259345.28	307450.43	31.27	29.60
chronos_bolt_small	24	259546.11	311466.37	31.32	29.63
xgboost	24	259549.38 ± 13.62	306563.19 ± 18.53	31.33 ± 0.00	29.63 ± 0.00
sarima	24	263913.91	316245.26	31.73	30.12
dlinear	24	278309.93 ± 78.45	327075.05 ± 121.45	34.58 ± 0.01	32.94 ± 0.01
patchtst	24	279295.35 ± 274.56	328419.63 ± 622.11	34.68 ± 0.04	33.05 ± 0.03
itransformer	24	283321.32 ± 278.79	335735.87 ± 639.05	35.11 ± 0.03	33.53 ± 0.03
seasonal_naive	24	338935.90	428088.82	39.98	38.69
xgboost	96	261792.58 ± 9.36	308906.88 ± 25.05	31.63 ± 0.00	29.94 ± 0.00
chronos_bolt_small	96	262601.94	314012.89	31.68	30.03
timesfm	96	262766.32	311382.39	31.65	30.05
sarima	96	267033.48	320436.95	32.07	30.54
dlinear	96	279227.54 ± 52.48	327146.57 ± 54.07	34.69 ± 0.01	33.07 ± 0.01
itransformer	96	279842.21 ± 148.37	327663.71 ± 205.90	34.75 ± 0.02	33.14 ± 0.02
patchtst	96	280109.77 ± 94.31	328333.77 ± 256.71	34.77 ± 0.02	33.17 ± 0.01
seasonal_naive	96	340658.82	428618.32	40.13	38.96
xgboost	168	264220.96 ± 24.77	311145.57 ± 42.08	31.96 ± 0.00	30.30 ± 0.00
chronos_bolt_small	168	264268.27	315996.95	31.91	30.30
timesfm	168	265044.60	313676.28	31.95	30.39
sarima	168	271294.60	325857.78	32.54	31.11
itransformer	168	279476.02 ± 103.81	326253.85 ± 265.79	34.75 ± 0.01	33.15 ± 0.01
dlinear	168	280272.56 ± 47.26	328134.31 ± 38.84	34.84 ± 0.01	33.25 ± 0.01
patchtst	168	280876.20 ± 109.22	328943.70 ± 263.11	34.88 ± 0.01	33.32 ± 0.01
seasonal_naive	168	343510.17	431537.72	40.48	39.39

Таблица II
Accuracy on ETTh1 test split.

Model	H	MAE	RMSE	sMAPE (%)	wMAPE (%)
chronos_bolt_small	24	3.00	4.78	44.88	29.73
patchtst	24	3.04 ± 0.01	4.56 ± 0.01	47.47 ± 0.18	30.09 ± 0.11
dlinear	24	3.08 ± 0.00	4.63 ± 0.00	47.95 ± 0.10	30.53 ± 0.04
timesfm	24	3.16	4.88	48.33	31.25
itransformer	24	3.25 ± 0.02	4.77 ± 0.04	49.29 ± 0.09	32.17 ± 0.15
seasonal_naive	24	3.31	5.44	46.07	32.78
sarima	24	3.45	4.92	52.92	34.15
xgboost	24	3.89 ± 0.01	5.40 ± 0.01	57.47 ± 0.08	38.50 ± 0.06
dlinear	96	3.55 ± 0.00	5.26 ± 0.01	54.11 ± 0.07	35.08 ± 0.02
chronos_bolt_small	96	3.57	5.61	51.08	35.30
patchtst	96	3.62 ± 0.03	5.27 ± 0.03	54.87 ± 0.36	35.79 ± 0.28
timesfm	96	3.67	5.61	54.27	36.24
itransformer	96	3.72 ± 0.01	5.43 ± 0.02	55.56 ± 0.24	36.81 ± 0.12
sarima	96	3.90	5.57	57.66	38.58
seasonal_naive	96	3.92	6.41	51.70	38.80
xgboost	96	4.21 ± 0.01	5.86 ± 0.01	61.21 ± 0.04	41.63 ± 0.05
dlinear	168	3.70 ± 0.00	5.43 ± 0.01	56.49 ± 0.08	36.54 ± 0.02
chronos_bolt_small	168	3.77	5.85	53.36	37.20
timesfm	168	3.79	5.75	55.77	37.38
itransformer	168	3.91 ± 0.02	5.62 ± 0.03	57.87 ± 0.23	38.62 ± 0.23
patchtst	168	3.95 ± 0.07	5.62 ± 0.08	58.51 ± 0.74	38.96 ± 0.74
sarima	168	4.18	5.87	60.30	41.22
seasonal_naive	168	4.18	6.70	54.20	41.26
xgboost	168	4.27 ± 0.01	5.98 ± 0.01	61.54 ± 0.04	42.15 ± 0.05

обучаемые нейросетевые модели. DLinear, PatchTST и iTransformer существенно превосходят SeasonalNaive, но не достигают точности древесной, фундаментальных или SARIMA-моделей при текущем бюджете обучения. Таблица эффективности (Табл. III) показывает компромисс при single-window latency: SeasonalNaive и SARIMA имеют наименьшие задержки, XGBoost остаётся быстрее нейросетевых моделей и TimesFM, Chronos-Bolt конкурентен, а TimesFM — самая медленная модель несмотря на сильную точность.

На ETTh1/HUFL Chronos-Bolt лучшая при H=24, при этом PatchTST — сильнейшая обучаемая модель на этом горизонте; DLinear лидирует при H=96 и H=168. TimesFM конкурентен, но не лучший на этом бенчмарке. SARIMA близок к лучшему классическому базовому методу и опережает XGBoost на всех трёх горизонтах — обратная ситуация по сравнению с ECL, где XGBoost доминирует над SARIMA. Результаты подтверждают важность одновременного включения линейных, трансформерных, фундаментальных и ARIMA-семейных базовых моделей: лучший класс

Таблица III
Computational efficiency.

Model	Data/H	Train s	Infer ms	Params	GPU MB
chronos_bolt_small	ecl/H24	0.000	15.6205	47718016	123.3
dlinear	ecl/H24	11.795	55.8597	16176	26.3
itransformer	ecl/H24	23.725	55.3372	311448	164.9
patchtst	ecl/H24	43.077	55.7089	168280	608.6
sarima	ecl/H24	109.773	2.9925	0	0.0
seasonal_naive	ecl/H24	0.000	0.0041	0	0.0
timesfm	ecl/H24	0.000	102.2329	200000000	895.6
xgboost	ecl/H24	2.892	7.5029	57388	0.0
chronos_bolt_small	ecl/H96	0.000	39.6397	47718016	345.8
dlinear	ecl/H96	18.843	59.4035	64704	29.8
itransformer	ecl/H96	31.380	66.2948	320736	165.0
patchtst	ecl/H96	49.984	62.4020	361888	612.4
sarima	ecl/H96	109.643	4.0940	0	0.0
seasonal_naive	ecl/H96	0.000	0.0048	0	0.0
timesfm	ecl/H96	0.000	91.9861	200000000	895.6
xgboost	ecl/H96	10.485	25.0947	229423	0.0
chronos_bolt_small	ecl/H168	0.000	45.2988	47718016	381.4
dlinear	ecl/H168	25.996	64.1642	113232	32.7
itransformer	ecl/H168	38.540	69.7238	330024	165.2
patchtst	ecl/H168	56.942	75.2900	555496	617.3
sarima	ecl/H168	108.428	5.5171	0	0.0
seasonal_naive	ecl/H168	0.000	0.0058	0	0.0
timesfm	ecl/H168	0.000	200.3501	200000000	896.4
xgboost	ecl/H168	18.179	42.7073	401454	0.0
chronos_bolt_small	etth1/H24	0.000	13.4838	47718016	123.3
dlinear	etth1/H24	10.701	39.9808	16176	26.2
itransformer	etth1/H24	20.171	39.1519	311448	164.8
patchtst	etth1/H24	39.820	39.1007	168280	608.3
sarima	etth1/H24	110.821	9.2978	0	0.0
seasonal_naive	etth1/H24	0.000	0.0037	0	0.0
timesfm	etth1/H24	0.000	98.1902	200000000	895.6
xgboost	etth1/H24	2.340	6.1449	57417	0.0
chronos_bolt_small	etth1/H96	0.000	36.2363	47718016	345.8
dlinear	etth1/H96	9.899	39.2943	64704	29.8
itransformer	etth1/H96	20.615	38.8574	320736	165.0
patchtst	etth1/H96	38.598	39.9531	361888	612.6
sarima	etth1/H96	110.801	11.8022	0	0.0
seasonal_naive	etth1/H96	0.000	0.0052	0	0.0
timesfm	etth1/H96	0.000	109.7588	200000000	895.6
xgboost	etth1/H96	8.638	24.4694	229758	0.0
chronos_bolt_small	etth1/H168	0.000	64.7316	47718016	381.4
dlinear	etth1/H168	10.095	40.7118	113232	32.6
itransformer	etth1/H168	21.127	44.3775	330024	165.1
patchtst	etth1/H168	39.072	42.3925	555496	617.0
sarima	etth1/H168	110.486	14.4646	0	0.0
seasonal_naive	etth1/H168	0.000	0.0053	0	0.0
timesfm	etth1/H168	0.000	208.5066	200000000	896.4
xgboost	etth1/H168	14.775	42.6873	401899	0.0

Таблица IV
Diebold–Mariano tests for top-2 models by MAE at seed 42.

Data/H	Comparison	Statistic	p-value	Sig.
ecl/H24	timesfm vs xgboost	13.45	<0.001	True
ecl/H96	xgboost vs chronos_bolt_small	-38.15	<0.001	True
ecl/H168	xgboost vs chronos_bolt_small	-2.88	0.004	True
etth1/H24	chronos_bolt_small vs patchtst	-3.39	<0.001	True
etth1/H96	dlinear vs chronos_bolt_small	-2.48	0.013	True
etth1/H168	dlinear vs chronos_bolt_small	-8.81	<0.001	True

моделей меняется от датасета и горизонта (Рис. 3, Рис. 5).

Статистические тесты подтверждают, что верхние сравнения не сводятся к небольшим численным различиям в плоском MAE. На ECL результаты при H=96 и H=168 отдают предпочтение XGBoost над Chronos-Bolt; при H=24 TimesFM и XGBoost практически идентичны в операционном смысле, и хотя тест Дибольда–Мариано отвергает гипотезу равной точности, абсолютная разница MAE менее 0.1% и операционно пренебрежима. На ETTh1/HUFL тесты подтверждают Chronos-Bolt при H=24 и DLinear на двух более длинных горизонтах. Это укрепляет центральное наблюдение: ни




Рис. 3. Тепловая карта MAE по датасетам и горизонтам.




Рис. 5. MAE по горизонтам.




Рис. 4. Accuracy-latency при H=96.




Рис. 6. MAE по горизонтам прогноза на ECL.

одно семейство моделей не доминирует одновременно по датасетам и горизонтам.

Accuracy-latency-визуализация (Рис. 4) и кривые MAE по датасетам (Рис. 6, Рис. 7) делают операционные режимы наглядными и согласуются с табличными ранжированиями.

VI. Обсуждение

Результаты показывают, что выбор модели зависит от датасета. На агрегированной нагрузке ECL инженерия лагов в комбинации с XGBoost остаётся крайне сильным и недорогим решением, а грид-настроенный SARIMA — следующая по точности модель, опережающая обучаемые нейросетевые архитектуры в этом сравнении. Фундаментальные модели привлекательны, когда отказ от обучения на целевом ряду имеет ценность: Chronos-Bolt близок к XGBoost на ECL и лучший на коротком горизонте ETTh1/HUFL. DLinear — сильнейшая обучаемая нейросетевая модель в этом бенчмарке и доминирует на длинных горизонтах ETTh1/HUFL.

С точки зрения развёртывания модели занимают разные операционные режимы. XGBoost — наиболее привлекательный выбор при допустимости стандартного supervised-пайплайна: точен на ECL, имеет малую single-window latency, не требует GPU. SARIMA — конкурентный недорогой запасной вариант без обучаемых признаков и с миллисекундной инференсной задержкой. Chronos-Bolt полезен, когда обучение на целевом ряду нежелательно, например в сценариях cold-start промышленного мониторинга, быстрой прототипизации или когда данные нельзя объединять для обучения.

TimesFM показывает сильную точечную точность на коротком горизонте ECL, но имеет существенно более высокую latency. DLinear — хороший нейросетевой референс: простой, компактный и сильный на длинных горизонтах ETTh1/HUFL.

Результаты трансформеров стоит читать осторожно. PatchTST и iTransformer — содержательные архитектуры, однако данный бенчмарк использует компактную одноцелевую конфигурацию и фиксированный бюджет обучения. Их относительная слабость здесь не означает общей непригодности трансформеров для прогноза нагрузки; она лишь показывает, что в условиях ограниченного и воспроизводимого протокола они не превосходят более простые методы автоматически. Производственное исследование должно включать более широкий перебор гиперпараметров, мультивариативные экзогенные входы и, возможно, датасет-специфичный тюнинг.

Основные ограничения связаны с риском контаминации фундаментальных моделей при претренине на открытых бенчмарках, ограниченным перебором гиперпараметров, одноцелевым моделированием и отсутствием закрытых промышленных данных развёртывания. Скользящий AutoARIMA как базовая модель пробовался, но полный per-origin grid search оказался непомерно дорогим в этом протоколе; частичный запуск сохранён в логах репозитория, но исключён из основных




Рис. 7. MAE по горизонтам прогноза на ETTh1/HUFL.

таблиц сравнения. Грид-настроенный SARIMA в этой работе — практическая замена: порядки выбираются на тренировочной выборке по AICs, и параметры повторно используются для окон прогноза, давая быстрый и чётко определённый ARIMA-базовый метод. Chronos-Bolt также выдаёт предупреждение о том, что длины прогноза свыше 64 находятся вне рекомендованного диапазона, поэтому результаты Chronos при $H=96$ и $H=168$ следует интерпретировать как практический стресс-тест, а не оптимальное использование модели.

Результаты фундаментальных моделей не следует чрезмерно интерпретировать как гарантированную zero-shot обобщающую способность на невиданных данных. ECL и ETTh1 — открытые бенчмарки, и они могут пересекаться с претренированными или оценочными корпусами, использовавшимися при разработке этих моделей. Корректное утверждение в этой работе уже: Chronos-Bolt и TimesFM запускались без обучения на целевом ряду в рамках данного репозитория. Это практически релевантно, но не равнозначно оценке на закрытом промышленном датасете.

VII. Заключение

Построен и исполнен воспроизводимый пайплайн STL-бенчмарка на ECL и ETTh1/HUFL. На ECL XGBoost, Chronos-Bolt и TimesFM статистически различимы, но операционно близки в пределах 0.4%, а грид-настроенный SARIMA — ближайший преследователь; на ETTh1/HUFL Chronos-Bolt лидирует при $H=24$, PatchTST — лучшая обучаемая модель на $H=24$, DLinear — при $H=96$ и $H=168$. Эти выводы поддерживают прагматичную рекомендацию: сравнивайте сначала с сильными простыми базовыми методами, включая корректно настроенную модель ARIMA-семейства, используйте DLinear и PatchTST как нейросетевые референсы, а фундаментальные модели рассматривайте как ценный инструмент для cold-start, а не как универсально доминирующую замену supervised-прогнозированию.

Список литературы

- [1] R. J. Hyndman and Y. Khandakar, “Automatic time series forecasting: The forecast package for r,” *Journal of Statistical Software*, vol. 27, no. 3, pp. 1–22, 2008.
- [2] T. Chen and C. Guestrin, “Xgboost: A scalable tree boosting system,” in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, pp. 785–794.
- [3] S. Hochreiter and J. Schmidhuber, “Long short-term memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [4] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, “Attention is all you need,” in *Advances in Neural Information Processing Systems*, 2017. [Online]. Available: <https://arxiv.org/abs/1706.03762>
- [5] H. Zhou, S. Zhang, J. Peng, S. Zhang, J. Li, H. Xiong, and W. Zhang, “Informer: Beyond efficient transformer for long sequence time-series forecasting,” in *Proceedings of the AAAI Conference on Artificial Intelligence*, 2021. [Online]. Available: <https://arxiv.org/abs/2012.07436>
- [6] A. Zeng, M. Chen, L. Zhang, and Q. Xu, “Are transformers effective for time series forecasting?” in *Proceedings of the AAAI Conference on Artificial Intelligence*, 2023. [Online]. Available: <https://arxiv.org/abs/2205.13504>
- [7] Y. Nie, N. H. Nguyen, P. Sinthong, and J. Kalagnanam, “A time series is worth 64 words: Long-term forecasting with transformers,” in *International Conference on Learning Representations*, 2023. [Online]. Available: <https://arxiv.org/abs/2211.14730>
- [8] Y. Liu, T. Hu, H. Zhang, H. Wu, S. Wang, L. Ma, and M. Long, “itransformer: Inverted transformers are effective for time series forecasting,” in *International Conference on Learning Representations*, 2024. [Online]. Available: <https://arxiv.org/abs/2310.06625>
- [9] H. Wu, T. Hu, Y. Liu, H. Zhou, J. Wang, and M. Long, “Timesnet: Temporal 2d-variation modeling for general time series analysis,” in *International Conference on Learning Representations*, 2023. [Online]. Available: <https://arxiv.org/abs/2210.02186>
- [10] A. Das, W. Kong, R. Sen, and Y. Zhou, “A decoder-only foundation model for time-series forecasting,” in *International Conference on Machine Learning*, 2024. [Online]. Available: <https://arxiv.org/abs/2310.10688>
- [11] A. F. Ansari, L. Stella, C. Turkmen, X. Zhang, P. Mercado, H. Shen, O. Shchur, S. S. Rangapuram, S. Pineda Arango, S. Kapoor, J. Zschiesner, D. C. Maddix, H. Wang, M. W. Mahoney, K. Torkkola, A. Gordon Wilson, M. Bohlke-Schneider, and Y. Wang, “Chronos: Learning the language of time series,” *Transactions on Machine Learning Research*, 2024. [Online]. Available: <https://arxiv.org/abs/2403.07815>